面向国产算力的多通道 AI Agent 运行底座【Xihe AI Assistant 】

开源项目 · Mulan PSL v2

```
# ========== 智能路由：联网→沐曦云端，断网→评估降级 ==========
    net_ok = is_network_available(force=True)
    if net_ok:
        # 联网：直接透传到沐曦云端，完整工具能力
        self._handle_muxi_request(data, model_id, stream_requested, raw_data)
        return
    else:
        # ===== 断网：智能评估任务复杂度 =====
        if is_task_suitable_for_local(messages, tools):
            # 简单任务：本地Ollama 4B兜底
            log.info("ROUTE: task SIMPLE -> local Ollama (qwen3.5:4b)")
        else:
            # 复杂任务：暂停等网络恢复，云端27B续传
            log.info("ROUTE: task COMPLEX -> pause with notice")
            self._handle_task_paused(data, model_id, stream_requested, raw_data, "")
            return
```

项目背景/整体思路/项目成果/社区贡献/开源历程

开源仓库https://www.gitlink.org.cn/LYL512/xihe-agent-runtime-fund

开源混合推理架构：屏蔽底层算力差异，实现端云无感协同

01 项目背景

02 整体思路

03 项目成果

04 社区贡献

05 开源历程

01 PART.

项目背景

行业痛点 × 国产算力生态缺口

1. 数据隐私与本地化需求爆发，但缺乏好用的开源本地化 AI
AI 框架，纯云端方案难/以满足开发者隐私诉求。

2. 国产算力（如沐曦C500）生态起步，开发者步，适配门槛高，缺乏开箱即用的开源上层 Agent 基础设施。

3. 纯云端开源项目高度依赖网络络，断网即瘫痪，社区亟需一套“联网高性能、断网有兜底”的高可用开源混合架构。

开发者与生态痛点

1. 开源开发者本地部署门槛高

•32B参数需32GB+显存
普通办公机（6-8GB）无法承载，高性能本地部署成本陡增。

2. 开源小模型能力天花板

•4B模型工具调用频繁幻觉
复杂推理不可靠，无法胜任多步办公任务（如生成PPT、操作文件）

3. 纯云端架构脆弱

•网络波动即服务中断
断网、超时、限流导致业务连续性无保障，不适合生产环境。

技术现状与开源困境

国产算力主力推理	沐曦C500 + Qwen3.5-27B Gitee.AI平台API调用，复杂推理+工具调用
本地模型离线兜底	qwen3.5:4b + RTX 4050 断网自动接管，数据不出域，零外部依赖
混合推理智能路由	网络状态检测 → 任务复杂度评估 简单任务本地4B，复杂任务沐曦32B
智能诊断自动降级	7分钟硬超时 + 诊断快照JSON 崩溃检测 → 自动fallback → 用户无感切换

这是在国产算力自主可控背景下，'云端主力+本地兜底'的混合推理架构，成为破解国产开源生态应用落地困境的关键路径。

02 PART.

整体思路

★ 本次提交的全部调用日志与性能数据，
均来自通道③（沐曦 C500 自部署 32B）
★ 通道①＝多源韧性对照项（云端 API：DeepSeek / 沐曦 Qwen3.5-27B，主力快通道）
★ 云端 API 不可用时 → 即时切至通道③，上层会话与工具不用改，系统不中断

应龙桥接器架构：上层体验不变，下层算力与模型可换

核心叙事：算力来源无关

① 入口层（用户侧）

多模态 IM 用户 → 接入网关 → 消息路由桥

浏览器 webchat → 直连网关

OpenClaw Gateway（核心调度）

会话管理 · MCP 工具调度 · 安全审批 | 开源框架复用

★ 核心原创资产：这一层完全不改动下层算力

③ 桥接层 ★ 核心：算力来源无关

应龙桥接器

三通道智能路由 | 断网无感降级 | 复杂任务暂停续传 | 协议双向适配

[多源对照项]

④ 算力层 · 三通道并列可切换

① 云端 API
通用云端API / 沐曦 Qwen3.5-27B
定位：云端主力，快且稳

② 本地 Ollama
qwen3.5:4b
定位：断网兜底，零成本

③ 沐曦 C500 自部署 32B
国产算力 · 重载任务

断网/超时/失败 Fallback 会自动降级切换模型

⑤ 看护层 · 多层自愈看护体系

进程级探活	会话级自愈	硬件级监控	C500 自动报警
（看门狗）	（自动解卡）	（C500 专属）	自动切换 Fallback

一次请求怎么走

阅读指南：按网络与任务自动选路

① 联网 → 走云端（DeepSeek）
② 断网 → 走本地（Ollama）
③ 复杂任务 → 走 C500
④ 故障 → 自动降级

底层算力可换，上层体验不变

环节一：双引擎 + Bridge 调度 · 智能分流与断网续传

整体流程

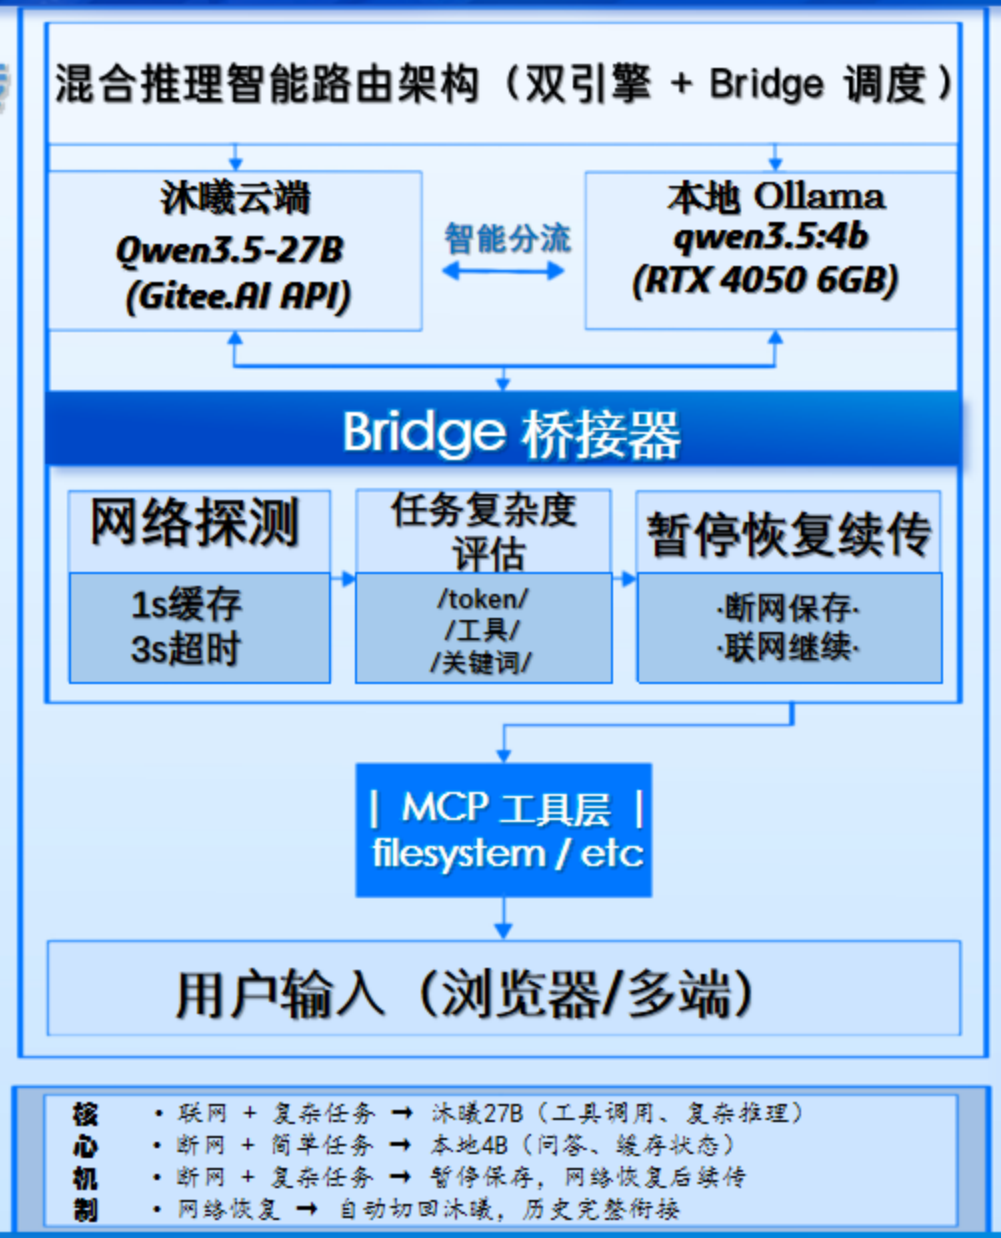
本地兜底

1. 断网自动接管者，简单任务实时处理 - Bridge每秒探测网络，断网后3秒内自动切换至本地qwen3.5:4b
   - 日常问答、短文本等轻量任务平均响应10秒，吞吐~38 tokens/s
2. 复杂任务智能暂停，状态无缝续传且数据安全- 任务复杂度超阈值(token>4000/工具>2/消息>500字)时自动暂停并保存JSON现场
   - 网络恢复后自动加载续传，对话完整衔接；完全离线运行，满足合规要求

调度中枢

云端主力

1. 国产沐曦GPU算力，支撑复杂办公任务与工具调用 - Bridge每 - 曦云C500 32GB + Qwen3.5-27B，处理长文档、多步推理、PPT/Word/Excel生成
   - MCP工具调用稳定（如filesystem列出20,082个文件），实测吞吐~39 tokens/s
2. 智能路由优先，断网恢复后自动衔接- 任务复杂度超阈值(token>4000/工具>2/消息>500字)时自动暂停并保存JSON现场



核心机制

- 联网 + 复杂任务 → 沐曦27B（工具调用、复杂推理）
- 断网 + 简单任务 → 本地4B（问答、缓存状态）
- 断网 + 复杂任务 → 暂停保存，网络恢复后续传
- 网络恢复 → 自动切回沐曦，历史完整衔接

以原创Bridge桥接器实现任务智能分流与断网续传，开源开放，让国产算力真正“用得起、用得好、不掉线”

环节二：混合推理架构·实测性能对比

：性能对比示例图—— 为什么选择混合架构?

混合推理

混合架构—扬长避短

联网高性能：中等总结任务沐曦27B吞吐39.4 t/s，输出精准不发散；25次MCP工具调用全部成功，复杂办公任务稳定执行。

断网不断线：网络中断后Bridge 3秒探测超时，自动无缝切至本地4B模型，10秒内恢复响应，简单问答不中断。

复杂任务续传：断网时自动暂停并保存JSON现场（含请求和已输出内容），网络恢复后自动加载续传，历史对话完整衔接。

云端 vs 本地 vs 混合

单一算力

纯云端方案（沐曦API直接调用）

断网即废：实测断网后Bridge socket探测超时，沐曦API请求挂起无返回，前端连续报错，业务完全中断。

成本不可控：中等总结任务单次消耗2048 completion tokens，按量计费模式下长期高频使用成本高。

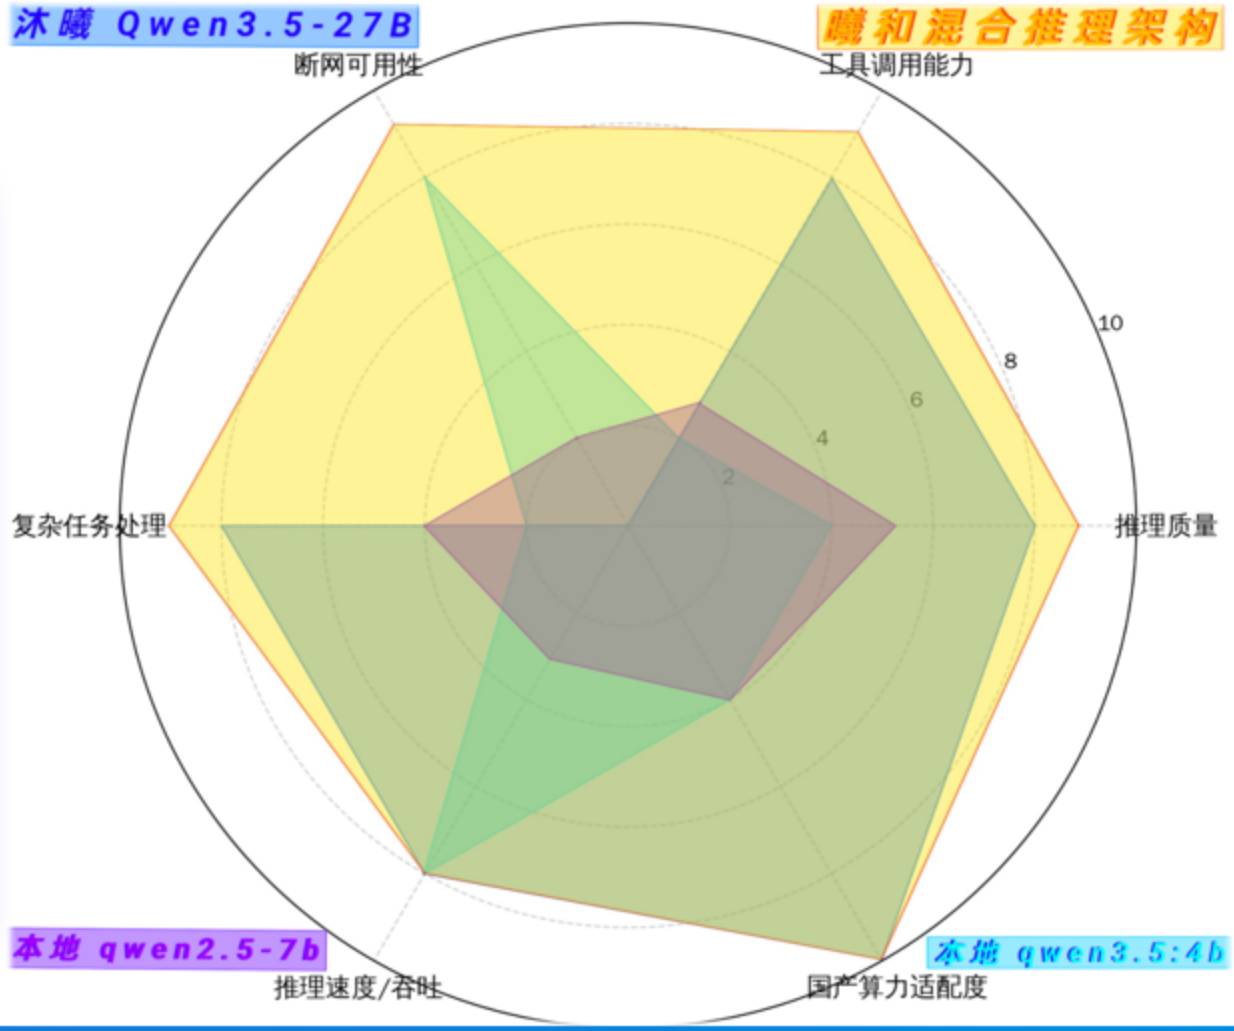
数据合规风险：数据经公网传输，无法满足无法满足开源开发者对隐私与本地化部署的诉求。

纯本地方案（qwen3.5:4b / qwen2.5-7b）

输出发散严重：中等总结任务要求200字，4B模型实际输出2095 tokens，内容冗余不可控。

硬件瓶颈致慢：7B模型在6GB显存下吞吐仅6.3 t/s，耗时65.8秒，CPU-GPU频繁交换。

工具调用不稳：4B模型易虚构MCP指令，复杂任务（如多步文件操作）无法稳定执行



基于实测数据证明：混合推理架构在不牺牲吞吐的前提下，实现了国产算力高性能与离线高可用的统一，为开源社区提供了一套可复现的参考方案。

03 PART.

项目成果

环节一：项目核心成果总览

国产算力适配

【沐曦 Qwen3.5-27B /(C500) 自部署 Qwen2.5—32B】

【合规声明】
- ☑真实运行验证，非模拟
- ☑通过Gitee.AI平台调用沐曦C500 GPU
- ☑提供性能报告（实测性能报告_20260525.txt)
- ☑提供完整调用日志（bridge_debug.log 5000+行)
- ☑在沐曦C500上完成Qwen2.5-32B-AWQ自部署与Agent接入

——模型——	吞吐量	任务类型	输出质量
沐曦 Qwen3.5-27B:	39.4 t/s	中等总结	★★★★★
(C500) 自部署 Qwen2.5—32B	314.84 t/s	批处理文件	★★★★★
DeepSeek V4.1 :	82.5 t/s	长文总结	★★★★★
本地 Qwen3.5:4B :	38.5 t/s	中等总结	★★★

【典型调用链路】
浏览器(用户) → OpenClaw Gateway(:18789)
→ Bridge 应龙桥接器(:11441)—[格式转换 + 流式裁剪 + 工具注入]
→ Gitee.AI 沐曦云端(:443) — Qwen3.5-27B 推理
→ 流式SSE返回 → Bridge转发 → Gateway → 用户

针对本地低显存环境，自适应调度轻量级模型

原创混合推理框架

联网时用沐曦云端做重活，断网时自动切本地保底，复杂任务可暂停续传。

通过原创 Bridge 桥接器实现

MCP 工具

【打通工具执行闭环】

【常规MCP工具已集成，以下是系统独有】

工具类别	工具名称	能力
算力路由	route_compute_channel	多模型/通道智能解析
算力切换	fallback_to_local	断网无感降级/任务续传
物理外设	lan_printer_daemon	局域网直连打印
物理检测	multimodal_extractor	多模态流提取与租户隔离
运维自愈	deadlock_resolver	会话死锁检测与自动解卡
端口查看	process_watchdog	进程探活、端口巡查与守卫
通信协同	async_broadcaster	多端异步进度播报与状态同步
邮件处理	smtp_gateway_agent	结构化邮件收发与附件解析

【从"对话"到"执行"】真实调用工具完成任务

•三大技术支柱•
•项目核心成果•

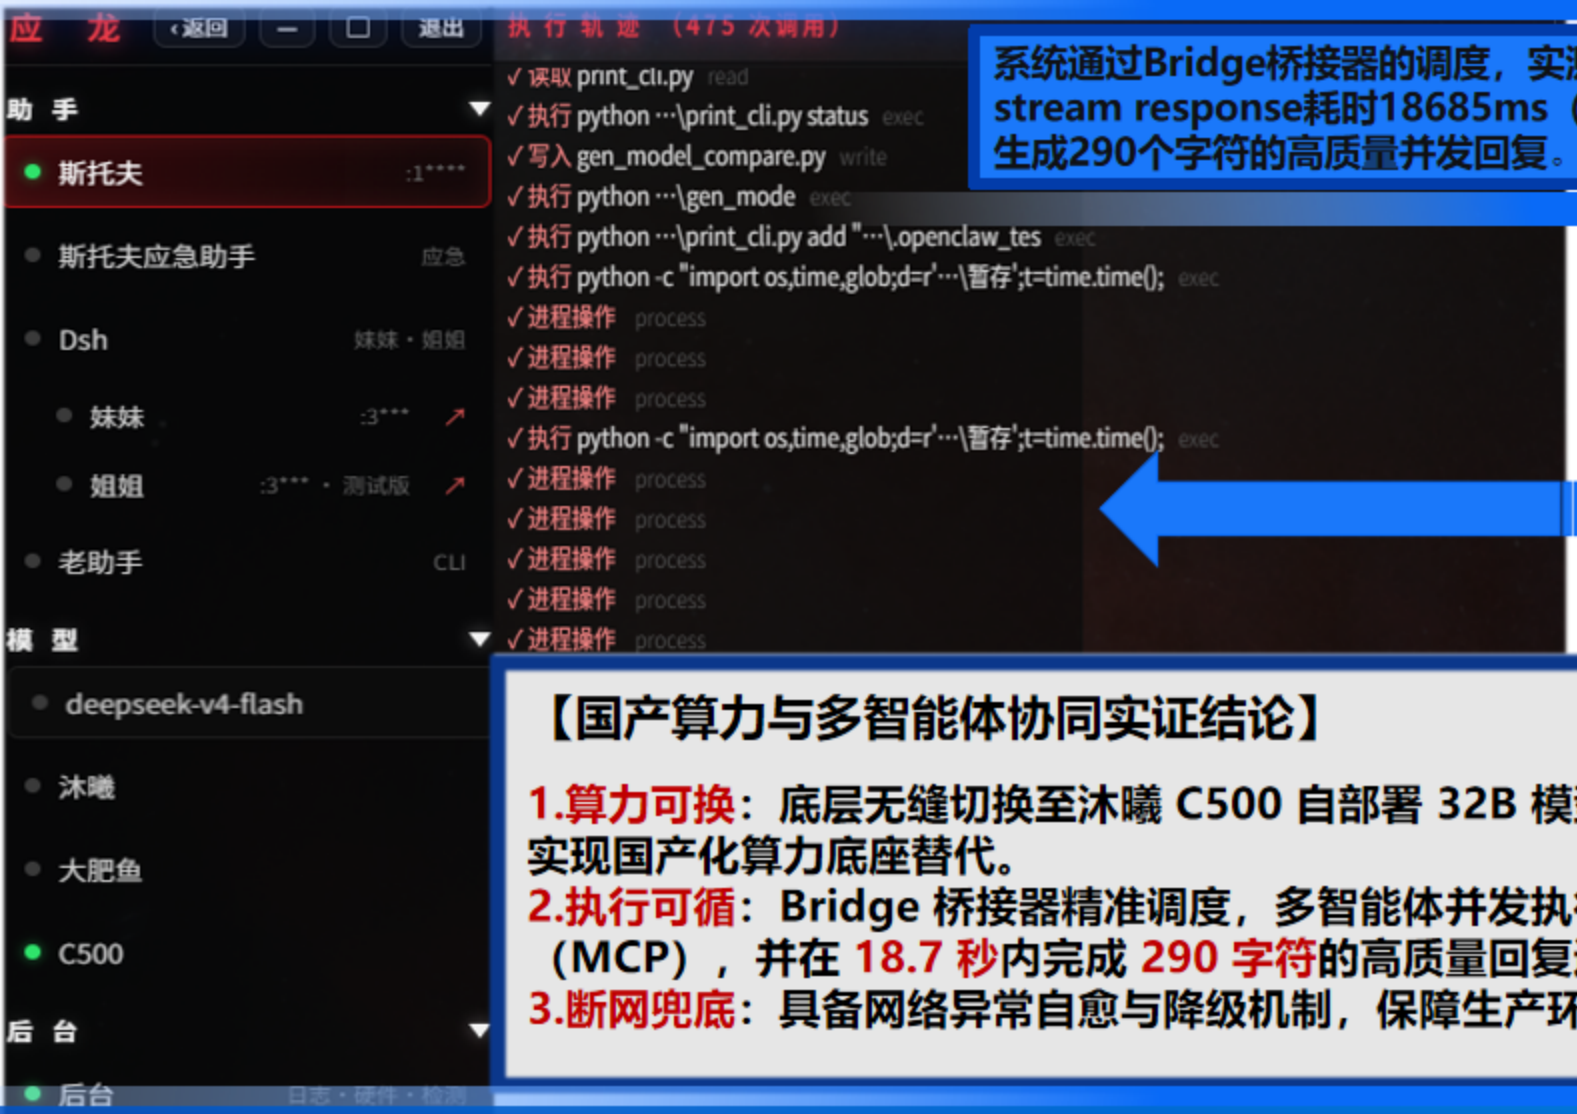
【传统单体架构】
单一模型串行处理 → 长上下文引发注意力稀释与幻觉 → 系统易崩溃

【本底座多智能体协同】
指令解析与分发 → 上下文动态隔离 →推理/检索/执行节点
并发调度→ 多模态闭环交付。

同时支持本地云端，双端调用,本地模型根据能力来看

同一套应龙桥接器，向下兼容多种异构算力，向上提供统一的 MCP 工具能力。

环节二：核心成果详细介绍 ——【国产算力适配】



系统通过Bridge桥接器的调度，实测中，Muxi stream response耗时18685ms（约18.7秒），生成290个字符的高质量并发回复。

【国产算力与多智能体协同实证结论】

1.**算力可换**：底层无缝切换至沐曦 C500 自部署 32B 模型，实现国产化算力底座替代。

2.**执行可循**：Bridge 桥接器精准调度，多智能体并发执行工具调用（MCP），并在 18.7 秒内完成 290 字符的高质量回复返还。

3.**断网兜底**：具备网络异常自愈与降级机制，保障生产环境100%不中断。

实测数据

真实调用

结果返还

国产不掉线

依托沐曦C500 GPU，Qwen3.5-27B主力模型稳定运行。

1.国产算力落地

2.工具交互闭环

3.混合架构保障

国产算力适配 + MCP 独有工具 + 混合推理 = 多通道 AI Agent 运行底座

环节三：核心成果详细介绍 ——【MCP 工具】

【系统独有MCP工具集成】

工具类别	工具名称	能力
算力路由	route_compute_channel	多模型/通道智能解析
算力切换	fallback_to_local	断网无感降级/任务续传
物理外设	lan_printer_daemon	局域网直连打印
物理检测	multimodal_extractor	多模态流提取与租户隔离
运维自愈	deadlock_resolver	会话死锁检测与自动解卡
端口查看	process_watchdog	进程探活、端口巡查与守卫
通信协同	async_broadcaster	多端异步进度播报与状态同步
邮件处理	smtp_gateway_agent	结构化邮件收发与附件解析

【底层实证：27个工具并发调度真实日志】
(配一行小字)：Bridge 实时探活路由至沐曦云端，返回 HTTP 200，端到端无崩溃。

```
oud (Qwen3.5-27B)
2026-06-26 19:27:05,929 INFO Injected keepalive + model status (Muxi Qwen3.5
-27B) into system prompt
2026-06-26 19:27:05,929 INFO Muxi request: model=Qwen3.5-27B, messages=2, st
ream=True, tools=27
2026-06-26 19:27:11,603 INFO HTTP: "POST /v1/chat/completions HTTP/1.1" 200
-
2026-06-26 19:27:15,402 INFO Muxi stream response: 14 chars, 9473ms
```

实测数据

沐曦云端模型在处理携带27个工具定义的请求时，从发出到收到HTTP 200响应，实测耗时约30秒，证明云端处理工具调用请求的响应效率。

按需分配

实测发现，45个工具定义会导致沐曦处理时间长达40-55秒。精简至27个高频核心工具后，响应时间降至20-30秒，降幅约30%，系统只保留模型能高效处理的工具集。

结果体现

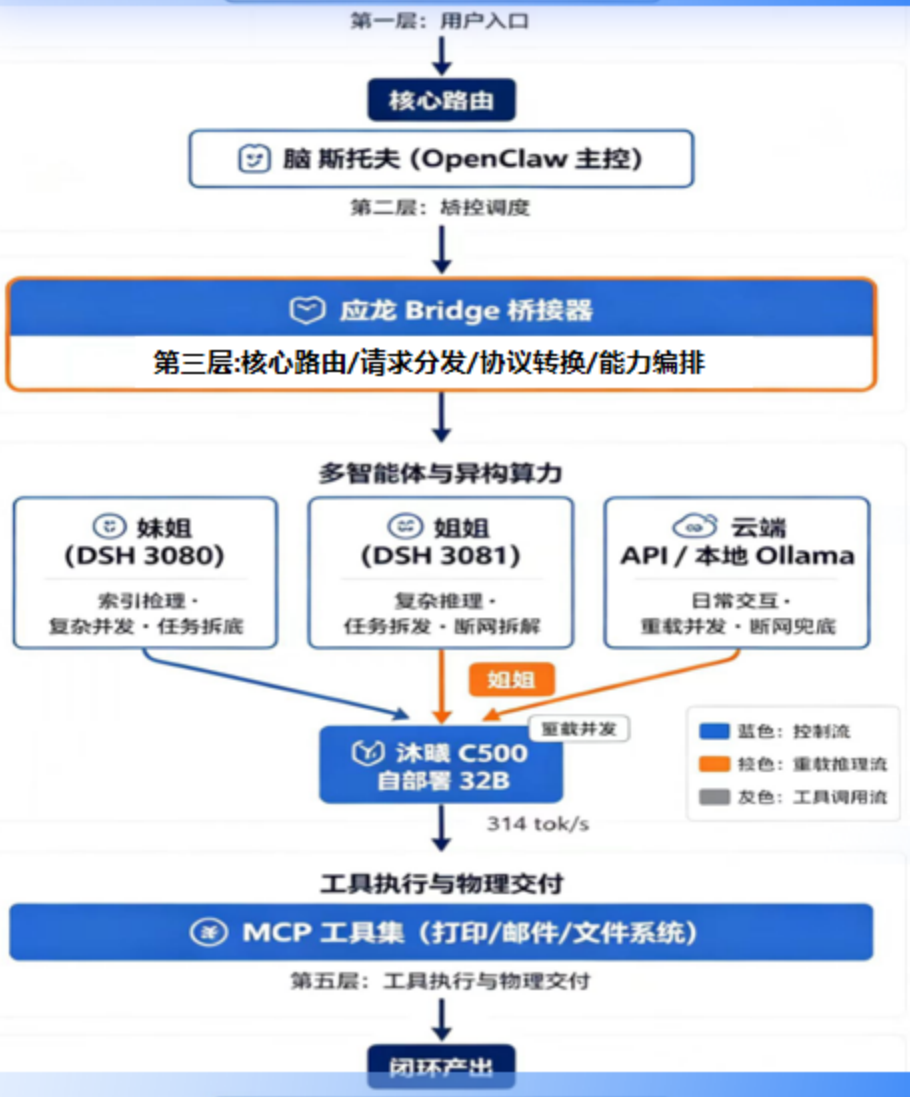
【系统落地成果】
物理交付闭环： 指令直达局域网打印机,实现零人工干预
无感容灾保障： 云端宕机秒切国产 C500，业务不中断
极致降本增效： 上下文隔离裁剪，实测 10元跑 1 亿Token

真实调用

1.真实算力落地
2.工具交互闭环
3.混合架构保障

国产算力适配 + MCP 独有工具 + 混合推理 = 多通道 AI Agent 运行底座

环节四：核心成果详细介绍 ——【原创混合推理框架】



【真实调用：意图解析与精准路由】

·底层日志全透明，27个 MCP 工具并发唤醒。

【分工协同：多智能体满血并行】

上下文彻底隔离，不会出现越聊越傻的情况。
重载任务直接交给底层的 C500，
跑出 314 tok/s 的吞吐。

【结果返还：端到端业务闭环】

无视底层代码差异，
直接驱动物理打印机出纸。

【断网无感容灾】

(请看实机演示视频)
运行中切断网络，业务 100% 不中断

真实调用
分工协同
结果返还
国产不掉线

1.真实算力落地
2.工具交互闭环
3.混合架构保障

分工协同
云端主力
断网保底

国产算力适配 + MCP 独有工具 + 混合推理 = 多通道 AI Agent 运行底座

04 PART.

社区贡献

环节一：【应龙桥接器（EGQ Bridge）—— 协议无关的智能路由引擎】

协议双向适配
【统一OpenAI与Ollama的API鸿沟】

Bridge在OpenAI原生tools参数（沐曦云端）与Ollama GGUF无tools能力之间构建透明适配层：
云端走原生tools→工具调用→返回结构化结果

无需修改OpenClaw框架一行代码

云端走原生tools→工具调用→返回结构化结果；
本地自动剥离tools参数→通过system prompt注入工具描述→兼容旧版GGUF

证据来源：bridge_competition.py 第248行 is_task_suitable_for_local() 函数（四维评估逻辑）、第80行 is_network_available() 函数（Socket TCP探测+1秒缓存）；logs/complex_task_demo.log.txt 中Bridge日志显示沐曦SSE

SSE流式保活与故障诊断
【透明的错误处理管线】

证据来源：logs/complex_task_demo.log.txt（总75事件，25+次工具调用，6次异常全部自动恢复）；diagnostics/snapshot_20260518_*.json 诊断快照结构；实测性能报告_20260525.txt 显示沐曦27B流式首token仅2-4秒

智能降级决策——多维任务复杂度评估

独创SSE流式双通道方案——云端chunk从沐曦直通Gateway保持同一chat_id，本地chunk从Ollama透传并过滤thinking标签。超时/崩溃时自动保存JSON诊断快照（含原始请求、消息角色链、工具列表、Ollama健康状态），支持事后根因分析。SSE心跳保活（防Gateway断连）配合内联降级信号替代HTTP重新握手。

智能降级决策
多维任务复杂度评估

证据来源：logs/complex_task_demo.log.txt（总75事件，25+次工具调用，6次异常全部自动恢复）；diagnostics/snapshot_20260518_*.json 诊断快照结构；实测性能报告_20260525.txt 显示沐曦27B流式首token仅2-4秒

断网不再是"全盘崩溃"或"全盘降级"二选一。Bridge引入4维度任务复杂度评估（token数4000阈值、工具数2阈值、用户消息长度500字符、16个复杂意图关键词），简单任务自动切本地4B快速响应，复杂任务暂停保存JSON文件并等待网络恢复后续传，避免本地小模型"打肿脸充胖子"产生低质量回复。

基于原创桥接器，打通端云协议鸿沟，实现智能路由、透明自愈——让国产算力真正“用得起、用得好、不掉线”

环节二：【混合推理架构的高可用设计与自愈机制】

三端容错链路
【四层自愈，零人工干预】

证据来源：logs/complex_task_demo.log.txt（Gateway超时3次→压缩→重试、Bridge连接中断2次→自动恢复、沐曦连接超时1次→fallback本地）【性能测试报告补充_Demo分析.md】第三条结论"异常自动恢复6/6（100%）"

从用户请求到模型响应的完整链路中
任何一层失效都不会导致**服务崩溃**

Gateway 180s超时→自动上下文压缩（compaction）→重试；Bridge 300s超时→保存诊断快照→SSE内联降级信号；沐曦API连接超时（ConnectionError 66s）→自动fallback本地Ollama；Ollama WinError 10053/10054崩溃→自动检测→恢复后重试

Demo全程23分钟历经6次异常
全部自动恢复（100%成功率）

国产算力主力+本地兜底
—沐曦 C500 重载 + 双擎自动路由—

证据来源：实测性能报告_20260525.txt 四模型对比表
沐曦27B: 51996ms/2048tokens/39.4t/s;
本地4B: 55045ms/2117tokens/38.5t/s;
沐曦 C500 自部署 (Qwen2.5-32B)
专攻：复杂推理、长文本生成、MCP 调度
实测吞吐：314.84 tok/s（顶配能力）

上线架构并非简单"云端不行就切本地"，而是实现能力分层：
沐曦Qwen3.5-27B (39.4 t/s，32GB显存全量加载)
承担复杂推理、长文本生成、MCP工具调度、长上下文处理；
本地Qwen3.5:4B (38.5 t/s，6GB VRAM)
承担基础问答和离线兜底。两个模型生成速度持平（39.4 vs 38.5 t/s），但27B质量显著更高，真正做到
"联网用贵的好的，断网用省的不崩"

多智能体上下文治理
--告别长文本幻觉与崩溃--

架构机制：上下文剥离与压缩
任务派发给姐姐/妹妹前，独立剥离上下文
确保每次满血执行；当 Gateway 遭遇超大文本（如 33K tokens 历史记录）时，自动触发 Context Compaction（上下文折叠）。

当Gateway + OEM框架触发大上下文【~33K tokens/77%预算】，**不上报错误中止任务**，而是**触发上下文压缩**【Context Compaction】；
真实日志实证（截图）
"logs/complex_task_demo.log" 中，系统在长达 23 分钟、25+ 次工具调用的极限重压下，成功执行了 4 次上下文压缩，用折叠后的精简摘要替换原始记录。

实现混合推理：四层容错、算力分层、自动压缩 —— 国产算力主力，本地模型兜底，服务永不中断。

05 PART.

开源历程

项目历程 · 四阶段演进

历时半年，从零搭建混合推理 AI 底座，打通本地与国产云端双算力，完成从架构设计到产品落地的完整闭环。

节点一：破冰

桥接器雏形诞生

起步与突围：从本地知识库起步，全面部署本地 Ollama 模型。为突破外部访问限制，自研代理服务器，成功跑通本地闭环。

路由初探：完成智能路由（Smart Routing）的初步开发，实现基于任务复杂度的多通道分发，以及超时分级与流内降级。

核心资产萌芽：在解决防幻觉与断网自愈的过程中，应龙桥接器（Bridge）的核心概念正式确立，代码雏形诞生。

关键证据：05-18_Bridge防幻觉与语言绑定修复.md / 05-20_Bridge智能路由实现.md

【4月 - 5月】

节点二：重构

生态接入与CCF获奖

全面接入 OpenClaw 框架

底层架构大换血：全面引入OpenClaw 核心调度框架，彻底重构底层逻辑,打通 MCP 工具链

智能中枢成型：应龙桥接器代码扩充至 670 行，实现多模型智能分发与断网降级；同时清洗 49 个合规文件，正式建立 GitLink 开源仓库。

行业权威认可：凭借扎实的底层工程与规范的仓库治理，最终斩获 第八届 CCF 开源创新大赛（国产 GPU 赛道）全国三等奖。

关键证据：05-19_沐曦云32B模型部署.md / 06-28_CCF提交归档

【5月 - 8月】

节点三：进化

国产算力与极限压测

【全面打通沐曦 C500 自部署 32B】

底层算力破局：成功跑通 沐曦 C500 自部署 32B（vLLM 0.17.0），形成云端 API/本地模型/C500 重载的三通道并行矩阵。

压测瓶颈突破：首轮16 并发压测发现调度瓶颈后,火速将轮询间隔从300s 优化至30s,彻底解决算力空转排队问题。

极致性能榨取：经过 83.4 分钟稳态重载压测，峰值吞吐达 314.84 t/s，压测窗 GPU 利用率狂飙至 80.5%。

关键证据：
2026-10-02_C500重载压测全纪实；
perf_loadtest_20261002.csv;

【9月 - 10月】

节点四：冲刺

开源治理与多智协同

极简开源治理：完成历史包袱剥离，仓库极限瘦身 99.3%，部署自动化脱敏扫描，双平台发布 v0.1.0 版本。

多智协同落地：多智能体（姐姐/妹妹）独立权限与 Agent 席位正式上线，具备断网自愈与容灾架构设计能力。

物理闭环与晋级：打通局域网物理打印，实现端到端交付；凭借底层实力，成功晋级超级龙虾挑战赛决赛。

关键证据：
10-13_本地初稿搭建_归档.md；
10-18_时间线与产出统计.md;

【10月】

未来展望：深化国产异构算力生态适配，推进多智能体在生产级复杂场景的规模化落地；完善底层架构，为千行百业提供高可用、零门槛的 AI 私有化运行底座。

破冰·重构·进化·冲刺 —— 让算力回归底层，让 AI 不止于对话，真正跨越数字与物理的边界。

谢谢

YOUTHFUL SKILLS

SHAPING THE FUTURE

【基于沐曦国产GPU的混合推理AI办公自动化系统】

面向国产算力的多通道 AI Agent 运行底座

【Xihe AI Assistant 】

项目背景/整体思路/项目成果/社区贡献/开源历程

开源仓库https://www.gitlink.org.cn/LYL512/xihe-agent-runtime-fund